

PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
NÚCLEO DE EDUCAÇÃO A DISTÂNCIA
Pós-graduação *Lato Sensu* em Ciência de Dados e Big Data

Rafael Santos Carvalho

**Predição da arrecadação de tributos: um comparativo entre o *Facebook*[™]
Prophet e as redes neurais *Long Short-Term Memory***

Varginha, Minas Gerais

2021

Rafael Santos Carvalho

PREDIÇÃO DA ARRECADAÇÃO DE TRIBUTOS: UM COMPARATIVO ENTRE O *FACEBOOK™ PROPHET* E AS REDES NEURAIS *LONG SHORT-TERM MEMORY*

Trabalho de Conclusão de Curso apresentado ao Curso de Especialização em Ciência de Dados e Big Data como requisito parcial à obtenção do título de especialista.

Varginha, Minas Gerais

2021

LISTA DE ABREVIATURAS E SIGLAS

CAGED – Cadastro Geral de Empregados e Desempregados

EMA – Erro Médio Absoluto

ICMS – Imposto sobre Circulação de Mercadorias e Serviços

IGP-M – Índice Geral de Preços - Mercado

IPVA – Imposto sobre a Propriedade de Veículos Automotores

ITCD – Imposto sobre Transmissão Causa mortis e Doação

LDO – Lei de Diretrizes orçamentárias

LOA – Lei Orçamentária Anual

LRF – Lei de Responsabilidade Fiscal

LSTM – *Long Short-Term Memory*

MAE – *Mean Absolut Error*

MLE – Maximum-likelihood Estimation

MLP – *Multilayer Perceptron*

PIB – Produto Interno Bruto

RS – Rio Grande do Sul

SUMÁRIO

1. Introdução.....	5
1.1. Contextualização	5
1.2. O problema proposto.....	6
2. Coleta de dados.....	8
3. Tratamento de dados.....	8
4. Análise e Exploração dos Dados	11
4.2. Os dados nominais.....	11
4.3. Os dados reais	13
5. Modelos preditivos para a arrecadação.....	19
5.1.1. Facebook™ Prophet	19
5.1.2. Redes neurais Long Short-Term Memory (LSTM)	19
5.2. Modelos com apenas uma variável quantitativa	20
5.2.1. Prophet.....	21
5.2.1.1. Utilizando o Prophet com remoção de <i>outliers</i>	21
5.2.1.2. Utilizando o Prophet sem remoção de <i>outliers</i>	25
5.2.2. Rede Neural LSTM	27
5.2.2.1. Padronização dos dados	27
6. Links	33
7. Referências.....	34

1. Introdução

1.1. Contextualização

Todo ente, seja ele município, estado federado ou a própria União possui o dever de realizar suas despesas de maneira harmônica com suas receitas, dever que, caso não cumprido, pode levar o ente a problemas fiscais como inadimplência de suas dívidas com fornecedores, atrasos dos pagamentos de aposentadorias, pensões e até mesmo dos salários do próprio funcionalismo. Além da própria crise fiscal que se origina da execução de despesas em montante superior ao das receitas, pode ainda o gestor público responder por crime de responsabilidade, conforme preceitua os artigos 10 e 11 da Lei 1.079/1950:

“CAPÍTULO VI
DOS CRIMES CONTRA A LEI ORÇAMENTÁRIA

Art. 10. São crimes de responsabilidade contra a lei orçamentária:

[...]

2 - Exceder ou transportar, sem autorização legal, as verbas do orçamento;

[...]

10 - captar recursos a título de antecipação de receita de tributo ou contribuição cujo fato gerador ainda não tenha ocorrido;

[...]

CAPÍTULO VII
DOS CRIMES CONTRA A GUARDA E LEGAL EMPREGO DOS DINHEIROS PÚBLICOS:

Art. 11. São crimes contra a guarda e legal emprego dos dinheiros públicos:

1 - ordenar despesas não autorizadas por lei ou sem observância das prescrições legais relativas às mesmas; [...]” (Brasil, 1950).

Já as Leis de Diretrizes Orçamentárias (LDOs) surgem para orientar a elaboração das Leis Orçamentárias Anuais (LOAs), estas que, por sua vez, determinam o orçamento do ente para determinado ano. Conforme a Lei de Responsabilidade Fiscal (LRF) cabem às LDOs:

“Art. 4º A lei de diretrizes orçamentárias atenderá o disposto no § 2º do art. 165 da Constituição e:

I - disporá também sobre:

a) equilíbrio entre receitas e despesas;

b) critérios e forma de limitação de empenho, a ser efetivada nas hipóteses previstas na alínea b do inciso II deste artigo, no art. 9º e no inciso II do § 1º do art. 31;

c) (VETADO)

d) (VETADO)

e) normas relativas ao controle de custos e à avaliação dos resultados dos programas financiados com recursos dos orçamentos;

f) demais condições e exigências para transferências de recursos a entidades públicas e privadas;

II - (VETADO)

III - (VETADO)

§ 1º Integrará o projeto de lei de diretrizes orçamentárias Anexo de Metas Fiscais, em que serão estabelecidas metas anuais, em valores correntes e constantes, relativas a receitas, despesas, resultados nominal e primário e montante da dívida pública, para o exercício a que se referirem e para os dois seguintes.

§ 2º O Anexo conterá, ainda:

I - avaliação do cumprimento das metas relativas ao ano anterior;

II - demonstrativo das metas anuais, instruído com memória e metodologia de cálculo que justifiquem os resultados pretendidos, comparando-as com as fixadas nos três exercícios anteriores, e evidenciando a consistência delas com as premissas e os objetivos da política econômica nacional;

III - evolução do patrimônio líquido, também nos últimos três exercícios, destacando a origem e a aplicação dos recursos obtidos com a alienação de ativos;

IV - avaliação da situação financeira e atuarial:

a) dos regimes geral de previdência social e próprio dos servidores públicos e do Fundo de Amparo ao Trabalhador;

b) dos demais fundos públicos e programas estatais de natureza atuarial;

V - demonstrativo da estimativa e compensação da renúncia de receita e da margem de expansão das despesas obrigatórias de caráter continuado.

§ 3º A lei de diretrizes orçamentárias conterá Anexo de Riscos Fiscais, onde serão avaliados os passivos contingentes e outros riscos capazes de afetar as contas públicas, informando as providências a serem tomadas, caso se concretizem.

§ 4º A mensagem que encaminhar o projeto da União apresentará, em anexo específico, os objetivos das políticas monetária, creditícia e cambial, bem como os parâmetros e as projeções para seus principais agregados e variáveis, e ainda as metas de inflação, para o exercício subsequente.” (Brasil, Lei Complementar 101/2000 – Lei de Responsabilidade Fiscal)

Percebe-se, portanto, que os gestores públicos estão sujeitos a diversos controles legais que visam a evitar que as despesas superem as receitas, estabelecendo metas, bem como a avaliação do cumprimento das metas estabelecidas em exercícios anteriores.

Sendo assim, a projeção das receitas é de suma importância para elaboração das Leis de Diretrizes Orçamentárias e das Leis Orçamentárias Anuais, bem como para a avaliação contínua pela Administração Pública da execução das despesas, com vistas a equilibrá-la à projeção de receitas, evitando *déficits* fiscais e infrações à Lei de Responsabilidade Fiscal.

1.2. O problema proposto

Para avaliar continuamente se as despesas programadas poderão efetivamente ser executadas sem gerar *déficit* fiscal, os gestores públicos necessitam de ferramentas que permitam prever a arrecadação futura para tomarem decisões acerca da continuidade, suspensão ou até mesmo o cancelamento da execução de

despesas. Geralmente as administrações tributárias realizam estimativas trimestrais e, quando necessitam de uma previsão em uma janela menor de tempo, utilizam previsões mensais. Muitas destas estimativas têm como objetivo ajustar as despesas a curto/médio prazo, bem como dar andamento a medidas burocráticas de aumento de receita, como solicitação de crédito suplementar, emissão de títulos da dívida pública e aumento de tributos, que necessitam de maior tempo para surtirem efeito, uma vez que estão quase sempre sujeitas ao processo legislativo.

Este trabalho visa encontrar métodos de predição em períodos mais curtos que os tradicionais, permitindo que gestores públicos prevejam a arrecadação em curtíssimo prazo (diariamente), permitindo tomada de decisões em caráter emergencial, principalmente no tocante à execução das despesas discricionárias, visando ao equilíbrio das contas públicas dos entes federados.

Para isso, serão utilizados dois algoritmos de predição de séries temporais (Facebook™ Prophet e redes neurais Long Short-Term Memory – LSTM) para analisar os dados diários de arrecadação tributária de três tributos estaduais do Rio Grande do Sul (Imposto sobre a Propriedade de Veículos Automotores – IPVA, Imposto sobre Transmissão Causa mortis e Doação – ITCD e Imposto sobre Circulação de Mercadorias e Serviços – ICMS) e estimar a arrecadação em datas futuras. Segundo dados do Portal da Transparência¹ do Estado do Rio Grande do Sul, em 2020 estes três tributos foram responsáveis por 63,53% da arrecadação estadual.

Receita	Valor	Percentual
ICMS	R\$ 36.380.727.217,60	57,27%
IPVA	R\$ 3.219.137.802,00	5,07%
ITCD	R\$ 759.805.762,52	1,20%
Contribuição Previdenciária	R\$ 18.933.532.080,80	29,80%
Outras Receitas	R\$ 4.231.732.386,74	6,66%
Total	R\$ 63.524.935.249,66	100,00%

Figura 1 – Valores e proporções da arrecadação por fonte de receita

Em um segundo momento, dados econômicos do estado do Rio Grande do Sul e nacionais serão agregados ao *dataset* dos dados de arrecadação de ICMS, permitindo avaliar a eficácia destas novas variáveis preditoras para a redução do erro dos modelos.

¹ Disponível em: <<http://www.transparencia.rs.gov.br/QvAJAXZfc/opensdoc.htm?document=Transparencia.qvw&host=QVS%40QLVPRO06&anonymous=true>>. Acesso em 7 de abril de 2021.

2. Coleta de dados

Os dados referentes à arrecadação diária de tributos do estado do Rio Grande do Sul foram coletados do Receita Dados², portal de dados da Secretaria Estadual de Fazenda do estado do Rio Grande do Sul. Já os dados do IGP-M para atualização dos valores dos demais *datasets* a valor presente (quando necessário) foram coletados do *IpeaData*³.

Quando da agregação de novos dados ao *dataset* de arrecadação, os dados serão também obtidos do *IpeaData*, sendo os dados do PIB trimestral do Rio Grande do Sul e de admissões e demissões mantidos na mesma escala que os coletados, uma vez que os dados de emprego, por não se tratarem de valores monetários, não estão sujeitos a alterações com o passar do tempo e os dados do PIB trimestral do estado já estão expressos em valores reais.

Os métodos que realizam as coletas de dados estão na classe *DownloadDados*, dentro de arquivo de mesmo nome, e abrangem leitura de arquivos CSV (arrecadação mensal, PIB mensal do Brasil e dados de admissões e demissões), leitura de arquivos do Microsoft Excel (PIB trimestral do RS) e *webscrapping* (IGP-M mensal).

3. Tratamento de dados

Uma vez que os valores coletados são nominais, estes serão ajustados a valor presente com base no IGP-M, índice que melhor reflete as alterações gerais de preço de mercado, tanto para consumidores (no caso do governo quando adquire produtos e serviços), quanto para produtores (no caso dos contribuintes, que pagam os tributos – principalmente o ICMS – sobre bases de cálculo que geralmente estão correlacionadas ao valor de mercado do bem, produto ou serviço). Sendo assim, a atualização dos valores de arrecadação pelo IGP-M permite a verificação da arrecadação real tanto pela ótica dos contribuintes quanto pela ótica do governo. Caso os valores não fossem atualizados a valor presente, os modelos de aprendizado de máquina teriam que lidar, além das variações reais da arrecadação, com as variações da inflação, o que provavelmente aumentaria o erro médio das predições.

² Disponível em: <[http://receitadados.fazenda.rs.gov.br/Arquivos/Arrecadação Diária.csv](http://receitadados.fazenda.rs.gov.br/Arquivos/Arrecadação%20Diária.csv)>. Acesso em 8 de abril de 2021.

³ Disponível em: <http://www.ipeadata.gov.br/ExibeSerie.aspx?stub=1&serid37796=37796&serid36482=36482>. Acesso em 8 de abril de 2021.

Já os valores do PIB nacional mensal foram ajustados pelo IGP-M da mesma forma que os dados de arrecadação, uma vez que da maneira que foram coletados estavam expressos em termos nominais.

Na coleta de dados do PIB nacional, foram necessários pequenos ajustes na exibição das datas (ajustes realizados nos métodos que fazem o *download* dos dados), que traziam dados do mês de outubro como sendo de janeiro. Já na coleta de dados de emprego do CAGED (admissões e demissões), além do ajuste das datas foi necessário o preenchimento de alguns campos que retornaram *NaN* (base de dados antiga), este preenchimento foi realizado com base no *download* de um terceiro *dataset* que continha os dados do saldo mensal de contratações, permitindo deduzir o valor de admissões ou demissões que estivessem sem valores válidos com base na subtração do saldo pelo campo (admissão ou demissão) que contivesse valores válidos para determinado mês.

```
@staticmethod
def download_dados_emprego():
    """ Baixa os dados de emprego do IPEA Data """

    # Baixa os dados de saldo de empregos para preencher campos que vierem
    # sem valores válidos
    url_saldo_caged_antigo = 'http://www.ipeadata.gov.br/ExibeSerie.aspx?oper=exportCSVBr&serid272844966=272844966&se-rid272844966=272844966'
    df_saldo_caged_antigo = pd.read_csv(url_saldo_caged_antigo, sep=';')
    df_saldo_caged_antigo['Data'] = df_saldo_caged_antigo['Data'].astype(str).str.replace('.', '/').replace('0000', '').str.replace('/1$', '/10')
    df_saldo_caged_antigo = df_saldo_caged_antigo.drop(df_saldo_caged_antigo.columns[2], axis=1)
    df_saldo_caged_antigo.columns = ['Data', 'Saldo']

    # Dados antigos do CAGED (Admissões e Demissões)
    url_caged_antigo = 'http://www.ipeadata.gov.br/ExibeSerie.aspx?oper=exportCSVBr&serid231410417=231410417&serid231410418=231410418'
    df_antigo = pd.read_csv(url_caged_antigo, sep=';')
    df_antigo['Data'] = df_antigo['Data'].astype(str).str.replace('.', '/').replace('0000', '').str.replace('/1$', '/10')
    df_antigo = df_antigo.drop(df_antigo.columns[3], axis=1)
    df_antigo.columns = ['Data', 'Admissoes', 'Demissoes']
    datas_nan = df_antigo['Data'][np.isnan(df_antigo['Demissoes'])==True] # Datas cujo valor de demissões é NaN
    saldos_nan = df_saldo_caged_antigo[df_saldo_caged_antigo['Data'].isin(pd.DataFrame(datas_nan)['Data'])] # Saldos em datas cujo valor de demissões é NaN
    df_antigo['Demissoes'][np.isnan(df_antigo['Demissoes'])==True] = df_antigo['Admissoes'][np.isnan(df_antigo['Demissoes'])==True]-saldos_nan['Saldo']
    df_antigo['Demissoes'] = df_antigo['Demissoes'].astype(int)

    # Dados novos do CAGED (Admissões e Demissões)
    url_caged_novo = 'http://www.ipeadata.gov.br/ExibeSerie.aspx?oper=exportCSVBr&serid2096725334=2096725334&serid2096725335=2096725335'
    df_novo = pd.read_csv(url_caged_novo, sep=';')
```

```

df_novo['Data'] = df_novo['Data'].astype(str).str.replace('.', '/').re-
place('0000', '').str.replace('/1$', '/10')
df_novo = df_novo.drop(df_novo.columns[3], axis=1)
df_novo.columns = ['Data', 'Admissoes', 'Demissoes']

df_final = df_novo.iloc[:, :-1].append(df_antigo.iloc[:, :-1]).reset_in-
dex(drop=True)

for i in range(0, len(df_final)):
    ano = df_final['Data'].str.split('/')[i][0]
    mes = df_final['Data'].str.split('/')[i][1]
    df_final['Data'].loc[i] = mes+'/'+ano

return df_final

```

Figura 2 – Download e tratamento de dados do CAGED

Após o tratamento dos dados antigos e novos foi realizada a junção dos dois *dataframes*, retornando um único Pandas *dataframe* como resultado.

Já as atualizações dos valores a valor presente são realizadas pelos métodos *corrige_inflacao* e *corrige_inflacao_pib* da classe *CorrigeValores* do arquivo *Util.py*, que verificam o período a que se referem os dados do PIB e da arrecadação e multi-
plicam pelo número índice, trazendo os valores a valor presente da última data dispo-
nível da série histórica do IGP-M.

```

@staticmethod
def corrige_inflacao(pd_tributo, pd_inflacao):
    """ Dado um dataframe com os números-índice para correção e outro data-
    frame com os valores de tributo,
    corrige estes trazendo-os ao valor presente da última data disponível no
    dataframe de valores de tributo. """

    ultimo_mes_inflacao = pd_inflacao.loc[0, 'Mes/Ano']
    ultimo_numero_indice = pd_inflacao.loc[0, 'Numero Indice']

    for indice, linha in pd_tributo.iterrows():
        mes_atual = linha['Data'].strftime("%m/%Y")

        ''' Nos meses anteriores à última data publicada para a inflação, o va-
        lor do tributo será
        multiplicado pela razão entre o último número-índice e o número índice
        correspondente ao mês seguinte ao do
        tributo. '''
        if datetime.strptime(mes_atual, '%m/%Y').date() < datetime.strptime(ul-
        timo_mes_inflacao, '%m/%Y').date():
            numero_indice_atual = pd_inflacao[pd_inflacao['Mes/Ano'] ==
            mes_atual]['Numero Indice'].item()
        elif datetime.strptime(mes_atual, '%m/%Y').date() >= date-
        time.strptime(ultimo_mes_inflacao, '%m/%Y').date():
            numero_indice_atual = ultimo_numero_indice

        pd_tributo.loc[indice, 'Valor'] = pd_tributo.loc[indice, 'Valor'] * ul-
        timo_numero_indice / numero_indice_atual

    return pd_tributo

@staticmethod
def corrige_inflacao_pib(pd_pib, pd_inflacao):

```

```

""" Dado um dataframe com os números-índice para correção e outro data-
frame com os valores do PIB Nominal,
corrige estes trazendo-os ao valor presente da última data disponível no
dataframe de valores de PIB."""

ultimo_mes_inflacao = pd_inflacao.loc[0, 'Mes/Ano']
ultimo_numero_indice = pd_inflacao.loc[0, 'Numero Indice']

for indice, linha in pd_pib.iterrows():
    mes_atual = linha['Data']

    ''' Nos meses anteriores à última data publicada para a inflação, o va-
lor do tributo será
multiplicado pela razão entre o último número-índice e o número índice
correspondente ao mês seguinte ao do
tributo. '''
    if datetime.strptime(mes_atual, '%m/%Y').date() < datetime.strptime(ul-
timo_mes_inflacao, '%m/%Y').date():
        numero_indice_atual = pd_inflacao[pd_inflacao['Mes/Ano'] ==
mes_atual]['Numero Indice'].item()
    elif datetime.strptime(mes_atual, '%m/%Y').date() >= date-
time.strptime(ultimo_mes_inflacao, '%m/%Y').date():
        numero_indice_atual = ultimo_numero_indice

    pd_pib.loc[indice, 'PIB'] = pd_pib.loc[indice, 'PIB'] * ultimo_nu-
mero_indice / numero_indice_atual

return pd_pib

```

Figura 3 – Métodos de atualização de valores a valor presente

4. Análise e Exploração dos Dados



4.2. Os dados nominais

No primeiro momento serão analisados os dados nominais dos tributos estaduais, com o objetivo de comparar com os dados reais, estes que serão efetivamente utilizados para treinamento e predição nos modelos. Para tanto, seguem abaixo os dados descritivos das séries temporais da arrecadação nominal dos três tributos estaduais:

Medida	ICMS	IPVA	ITCD
Quantidade	3.167,00	3.119,00	3.097,00
Média	104.326.511,37	9.263.437,50	1.709.255,15
Desvio Padrão (σ)	145.973.777,35	18.156.530,23	2.582.832,55
Mínimo	-153.507,11	-167,22	-1.375,75
25%	16.454.912,34	1.829.823,52	612.259,54
50%	39.408.950,31	4.662.392,00	1.184.296,94
75%	145.005.742,05	9.745.511,49	2.011.134,15

Máximo

1.164.392.552,98 294.336.676,91 62.862.554,05

Figura 4 – Descrição da arrecadação nominal dos tributos estaduais*Figura 5 – Arrecadação nominal do ICMS do RS**Figura 6 – Arrecadação nominal do IPVA do RS*




Figura 7 – Arrecadação nominal do ITCD do RS

Denota-se que o ICMS, além de possuir um maior valor médio nominal de arrecadação, é o tributo que possui maior variância (σ^2), o que certamente aumentará o valor do erro médio dos modelos que serão desenvolvidos. Outro aspecto a ser comentado é a existência de valores negativos, mesmo que em menor valor absoluto, nas séries. A existência de arrecadação negativa se deve ao fato de que dos valores computados já estão deduzidas as restituições e benefícios fiscais, sendo os meses com valores negativos, portanto, aqueles em que as restituições e/ou benefícios fiscais excederam a arrecadação bruta. Observando os gráficos, percebe-se visualmente que todas as séries possuem tendência de crescimento nominal, o que já era esperado por conta da inflação. Outra característica interessante é a sazonalidade da arrecadação do IPVA nos primeiros meses do ano devido aos pagamentos à vista e das primeiras parcelas. No ITCD percebem-se alguns picos de arrecadação, mas não fica visualmente claro se há alguma sazonalidade.

4.3. Os dados reais

Atualizando os valores a valor presente, fica observado o aumento da magnitude dos novos números. Como a variância é, como também dito na análise dos valores nominais, fator que impacta diretamente o desempenho do modelo, o aumento

desta medida, decorrido da atualização, aumentará o desafio para que os modelos prevejam a arrecadação com grau aceitável de erro.

Medida	ICMS	IPVA	ITCD
Quantidade	3.167,00	3.119,00	3.097,00
Média	176.546.450,23	15.716.591,77	2.767.067,95
Desvio Padrão (σ)	225.599.315,66	29.589.472,15	4.523.596,03
Mínimo	-209.539,42	-356,90	-3.004,87
25%	27.993.106,87	3.130.045,03	1.216.229,59
50%	68.630.690,51	8.435.535,40	2.003.726,62
75%	259.310.821,37	17.177.296,69	3.063.960,79
Máximo	1.560.701.121,06	421.701.485,08	113.094.527,20

Figura 8 – Descrição da arrecadação real dos tributos estaduais




Figura 9 – Arrecadação real do ICMS do RS




Figura 10 – Arrecadação real do IPVA do RS




Figura 11 – Arrecadação real do ITCD do RS

Após a atualização dos valores, percebe-se que a tendência de aumento ficou reduzida em todas as séries quando em comparação com os valores nominais. Com a inflação eliminada dos dados, parte-se para uma análise mais aprofundada destes.




Figura 12 – Boxplot da arrecadação real do ICMS do RS




Figura 13 – Boxplot da arrecadação real do IPVA do RS

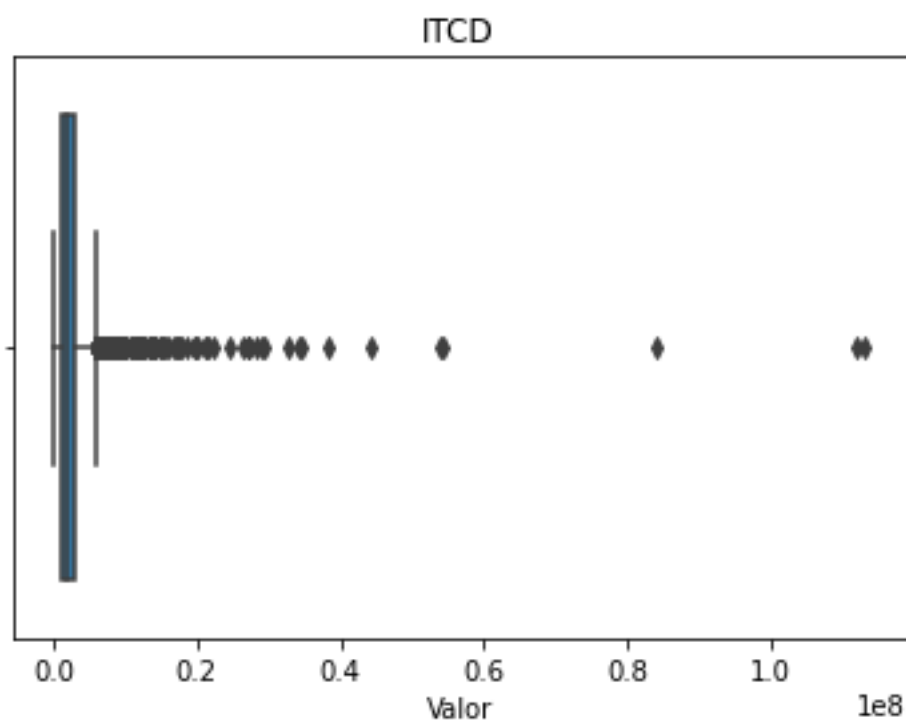


Figura 14 – Boxplot da arrecadação real do ITCD do RS




Figura 15 - Distribuição de probabilidades da arrecadação real do ICMS




Figura 16 - Distribuição de probabilidades da arrecadação real do IPVA




Figura 17 - Distribuição de probabilidades da arrecadação real do ITCD

Pela amplitude dos *boxplots* é possível verificar a variância das séries temporais da arrecadação dos tributos. O ICMS, com variância bem superior aos demais, é o que possui maior intervalo interquartílico, seguido pelo IPVA e ITCD, com menores variâncias. O mesmo ocorre com os *outliers*, estando presentes em maior quantidade no ICMS do que nos demais tributos. Sendo valores que têm grande potencial de

atrapalharem as previsões, os *outliers* devem passar por tratamento para que suas importâncias sejam reduzidas. Além disso, cada modelo preditivo comporta-se de maneira distinta em relação aos tratamentos, devendo ser escolhido o melhor método para cada modelo. Neste trabalho, para os modelos utilizando redes neurais LSTM, os dados serão tratados com três *scalers* do pacote *scikit-learn*: *StandardScaler*, *RobustScaler* e *PowerTransformer* e mantido aquele que apresentar menor erro para cada modelo. Já para o Prophet o trabalho seguirá as orientações especificadas no *paper Forecasting at Scale*⁴, que deu origem ao algoritmo, e as orientações da documentação do Prophet⁵, removendo os outliers.

5. Modelos preditivos para a arrecadação

5.1.1. Facebook™ Prophet

O Facebook™ Prophet é uma biblioteca que permite a previsão de séries temporais de forma acurada e rápida. Conforme a página da biblioteca⁶, o Prophet é capaz de lidar com previsão de séries temporais com tendências não-lineares, preenchendo-as com sazonalidade anual, semanal e/ou diária. Como observação, a página indica que o algoritmo performa melhor em séries temporais com fortes efeitos sazonais e várias “temporadas” de dados históricos. Sendo assim, espera-se que as previsões da arrecadação do IPVA performem melhor que as do ICMS e ITCD, uma vez que a arrecadação daquele é visivelmente mais sazonal que as destes.

Na mesma página ainda é informado que modelos do Prophet lidam bem com *missing data* e *outliers*, além de lidar bem com mudanças de tendência. Com relação a estes pontos não há nos *dataframes* deste trabalho casos que exijam tratamento diferenciado de *missing values*, uma vez que dados ausentes puderam ser preenchidos com consultas a outras bases de dados. Com relação aos *outliers*, uma vez que o objetivo é buscar o menor erro no modelo, será adotado o procedimento descrito no final do item 4.3 (remoção de *outliers*) e também a comparação com modelo sem a remoção destes valores, verificando o que melhor performa.

5.1.2. Redes neurais Long Short-Term Memory (LSTM)

⁴ Disponível em: <<https://peerj.com/preprints/3190.pdf>>. Acesso em 12 de abril de 2021.

⁵ Disponível em: <<https://facebook.github.io/prophet/docs/outliers.html>>. Acesso em 12 de abril de 2021.

⁶ Disponível em: <<https://facebook.github.io/prophet/>>. Acesso em 12 de abril de 2021.

Criadas em 1997 por Sepp Hochreiter e Jürgen Schmidhuber, as redes neurais LSTM permitem a predição de séries temporais utilizando neurônios de entrada de três dimensões (tamanho do lote – *batch size*, tamanho da janela temporal – *timesteps* e quantidade de *features* para cada janela temporal – *input dimension*), diferentemente das redes neurais *Multilayer Perceptron* (MLP) que necessitam apenas de *dataframes* com duas dimensões (*batch size* e *input dimension*). Constituem um tipo de modelo altamente sensível a *outliers* e *missing values*, devendo ser tratados adequadamente, como descrito ao final do item 4.3.

Neste trabalho a transformação dos *dataframes* em *dataframes* de três dimensões é realizada pelo método *cria_intervalos_temporais* da classe *LSTMUtil*, dentro do arquivo *ModelosUtil.py*.

```
@staticmethod
def cria_intervalos_temporais(np_array, n_intervalos=5):
    """ Dado um array NumPy com os valores diários, gera sequências tempo-
        rais com 3 dimensões
        para alimentarem a rede neural LSTM. """

    np_valores = np_array
    np_sequencia = np.empty((0, n_intervalos, 1))

    for i in range(n_intervalos, len(np_valores)):
        # Adiciona os itens que comporão uma sequência
        # Cada item é composto por uma sequência, n_intervalos intervalos
        # de tempo e 1 feature)
        np_item = np.empty((0, n_intervalos, 1))
        np_item = np.append(np_item, np_valores[(i-n_intervalos):i,
0].reshape(1, n_intervalos, 1), axis=0)
        # Adiciona uma sequência à lista de sequências
        np_sequencia = np.append(np_sequencia, np_item, axis=0)

    return np_sequencia
```

Figura 18 – Método de transformação de arrays NumPy de duas dimensões em arrays de três dimensões

Os modelos LSTM serão construídos com base na API Funcional (*Functional API*) do *Keras*, permitindo maior flexibilidade que a tradicional e mais simples API Sequencial (*Sequential API*), como, por exemplo, o uso de camadas *Embedding* para utilizar parâmetros das datas, como dia e mês, como inputs do modelo sem que sejam necessariamente tratados como *features* dentro das janelas temporais (uma vez que datas sempre são sequenciais, a adição de todas as datas em todos os *timesteps* tornaria o modelo mais lento sem acrescentar poder preditivo). Sendo assim, a API Funcional permite a integração entre vários tipos de camadas e até mesmo dimensões em um único modelo.

5.2. Modelos com apenas uma variável quantitativa

Os modelos com apenas uma variável quantitativa serão alimentados apenas com os valores das datas e da arrecadação, ou seja, buscarão realizar as previsões utilizando somente a autocorrelação e sazonalidade como fatores preditivos.

5.2.1. Prophet

5.2.1.1. Utilizando o Prophet com remoção de *outliers*

Os *dataframes* de treino e teste foram divididos na proporção de 80% e 20%, respectivamente, do *dataframe* inicial. No primeiro momento serão retirados o *dataframe* de treino os *outliers*, sendo considerados como *outliers* aqueles valores que estiverem acima de 1,5 desvio quartil acima do terceiro quartil e abaixo de 1,5 desvio quartil abaixo do primeiro quartil. O método *transforma_dataframe* da classe *ProphetUtil* é responsável por converter o *dataframe* inicial em um *dataframe* no formato aceito pelo Prophet, com uma coluna com o nome “ds”, contendo as datas, e outra com o nome “y”, contendo os valores.

```
@staticmethod
def transforma_dataframe(df, list_colunas):
    """ Dado um dataframe e uma lista com as colunas de data e e valor
    (nesta ordem), retorna um dataframe
    para que possa ser feito o 'fit' no Prophet. """
    pd_prophet = pd.DataFrame(df).loc[:, list_colunas]
    pd_prophet[list_colunas[0]] = to_datetime(pd_prophet[list_colunas[0]])

    return pd_prophet.rename(columns={list_colunas[0]: 'ds', list_colu-
nas[1]: 'y'}).reset_index(drop=True)
```

Figura 19 – Método de transformação do dataframe em um dataframe do Prophet

O treinamento do modelo é realizado pelo método *fit* da classe *Prophet* e a predição é realizada pelo método *predict* da mesma classe. Retornadas as previsões para cada tributo, são gravados os erros e as datas dos *dataframes* de testes e plotados os gráficos com os resultados.

```
# Predição com a remoção de 'outliers'
for tributo in pd_arrecad_diaria['Tributo'].unique():
    # Calcula os valores em termos absolutos
    prophet = Prophet(daily_seasonality=True)

    pd_prophet = ProphetUtil.transforma_dataframe(arrecad_diaria[tributo],
['Data', 'Valor'])
    df_treino, df_teste = ProphetUtil.divide_treino_teste(pd_prophet)

    # Remove os 'outliers' do dataframe de treino
    primeiro_quartil = df_treino['y'].quantile(.25)
    terceiro_quartil = df_treino['y'].quantile(.75)
    desvio_quartil = (terceiro_quartil - primeiro_quartil) / 2
    df_treino = df_treino[(df_treino['y'] < terceiro_quartil + 1.5 * desvio_quar-
til) & (df_treino['y'] > primeiro_quartil - 1.5 * desvio_quartil)]
```

```

df_teste.reset_index(drop=True, inplace=True)
prophet.fit(df_treino)
predito = prophet.predict(pd.DataFrame(df_teste['ds']))

# Grava os erros
rmse = mean_squared_error(pd.DataFrame(df_teste['y']).values, pre-
dito['yhat'].values) ** (1 / 2)
mae = mean_absolute_error(pd.DataFrame(df_teste['y']).values, pre-
dito['yhat'].values)

# Plota as previsões
fig, (sub1) = plt.subplots(1, 1, sharex=True)
sub1.fill_between(df_teste['ds'], predito['yhat_upper'], pre-
dito['yhat_lower'], facecolor='dodgerblue')
pred, = plt.plot(df_teste['ds'], predito['yhat'], c='blue', label='Pre-
dito')
pred_sup, = plt.plot(df_teste['ds'], predito['yhat_upper'], c='royal-
blue')
pred_inf, = plt.plot(df_teste['ds'], predito['yhat_lower'], c='royal-
blue')
real = plt.scatter(df_teste['ds'], df_teste['y'], s=3, c='orange')
plt.legend([pred, pred_sup, real],
           ['Predito', 'Predito (limites superior e inferior)', 'Re-
al'],
           fontsize=8)
fig.autofmt_xdate()
plt.xlabel('Data')
plt.ylabel('Valor (R$)')
plt.title(tributo)
plt.show()

pd_datas_testes.loc[tributo+' - Prophet - Univariável - Com Remoção de
Outliers', 'Inicio'] = df_teste.reset_index().loc[0, 'ds']
pd_datas_testes.loc[tributo+' - Prophet - Univariável - Com Remoção de
Outliers', 'Fim'] = df_teste.reset_index().loc[len(df_teste) - 1, 'ds']
pd_datas_treinos.loc[tributo+' - Prophet - Univariável - Com Remoção de
Outliers', 'Inicio'] = df_treino.reset_index().loc[0, 'ds']
pd_datas_treinos.loc[tributo+' - Prophet - Univariável - Com Remoção de
Outliers', 'Fim'] = df_treino.reset_index().loc[len(df_treino) - 1, 'ds']
pd_performance.loc[tributo+' - Prophet - Univariável - Com Remoção de
Outliers', 'MAE'] = mae
pd_performance.loc[tributo+' - Prophet - Univariável - Com Remoção de
Outliers', 'RMSE'] = rmse
pd_stats.loc[tributo+' - DP', 'dp'] = df_teste['ds'].std()

# Plota os componentes
prophet.plot_components(predito)

```

Figura 20 – Trecho do código em que é feita a previsão pelo Prophet com a remoção de outliers

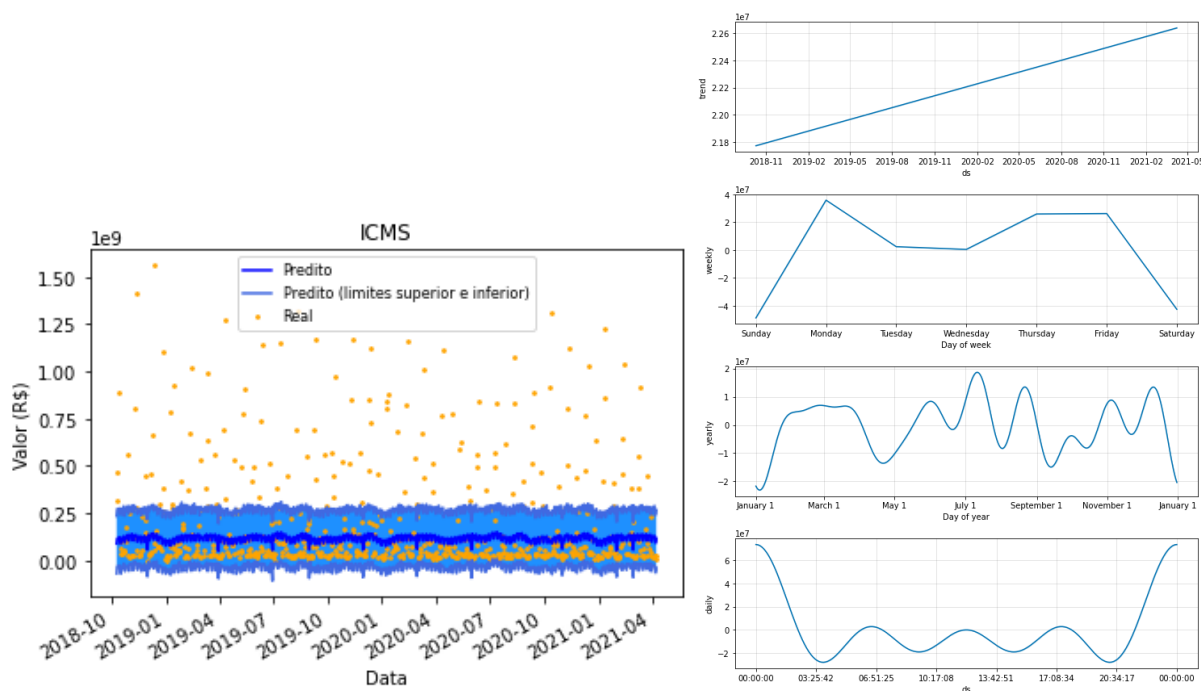


Figura 21 – Predição da arrecadação do ICMS (à esquerda) e componentes da predição (de cima para baixo: tendência, sazonalidade semanal, anual e diária), com remoção de outliers

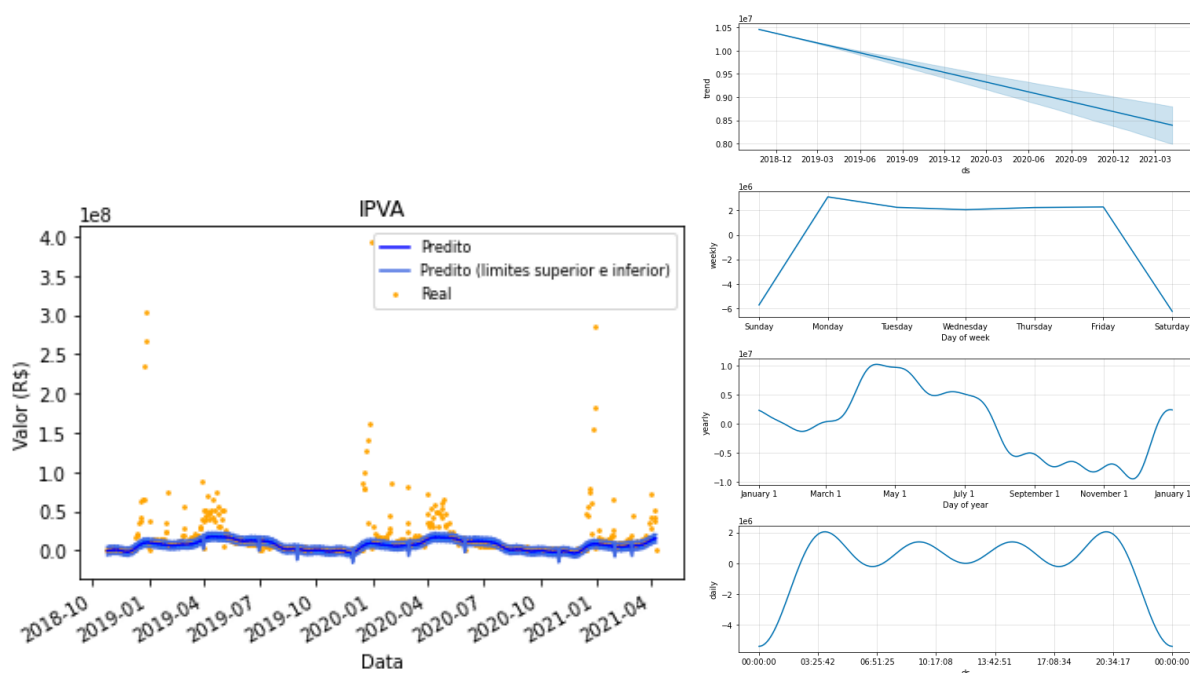


Figura 22 – Predição da arrecadação do IPVA (à esquerda) e componentes da predição (de cima para baixo: tendência, sazonalidade semanal, anual e diária), com remoção de outliers

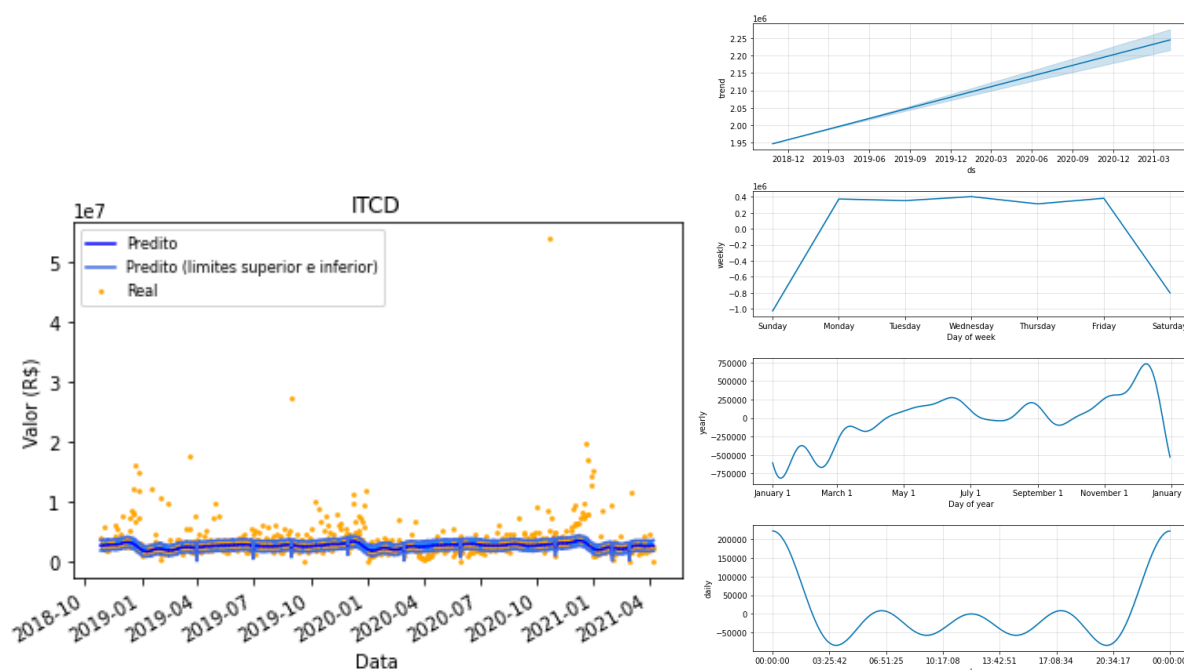


Figura 23 – Predição da arrecadação do ITCD (à esquerda) e componentes da predição (de cima para baixo: tendência, sazonalidade semanal, anual e diária), com remoção de outliers

Tributo	RMSE (A)	Desvio Padrão set de testes (B)	A/B = (C)
ICMS	285.511.789,84	277.909.138,33	1,027357
IPVA	33.424.786,01	33.042.123,48	1,011581
ITCD	3.388.334,97	3.311.754,46	1,023124

Figura 24 – Root Mean Squared Error dos resíduos das predições do Prophet, com exclusão de outliers

Com a exclusão dos *outliers* do set de treinamento, percebe-se que os modelos preditivos para os três tributos permanecem praticamente inalterados quando da ocorrência de *outliers* nos *datasets* de testes. Quanto aos componentes das predições, verifica-se que, com exceção ao IPVA, há uma tendência de crescimento. A sazonalidade semanal é praticamente inexistente para os três tributos, enquanto a sazonalidade anual fica clara principalmente para o IPVA na primeira metade do ano e fica maior para o ITCD à medida que o final do ano se aproxima. Já para o ICMS não há uma sazonalidade muito clara, alternando entre topos e fundos no decorrer do ano. Quanto aos resíduos, todos os tributos tiveram predições com a razão entre a raiz quadrada do erro quadrático médio (A) pelo desvio padrão do set de testes (B) maior que 1, o que é pouco satisfatório para fins preditivos, mas considerando um modelo que apenas avalia a sazonalidade, sem relacionar outros fatores, possui um bom

desempenho. O uso da métrica C, descrita como a razão de A e B visa avaliar os modelos sem penalizá-los nas previsões de séries temporais com variância elevada.

5.2.1.2. Utilizando o Prophet sem remoção de *outliers*

Para fins comparativos, serão executados os mesmos procedimentos do item 5.2.1.1, com exceção da exclusão dos *outliers*, mantendo-se, portanto, todos os dados no *dataset* de treinamento, deixando o Prophet tratar os *outliers* automaticamente.

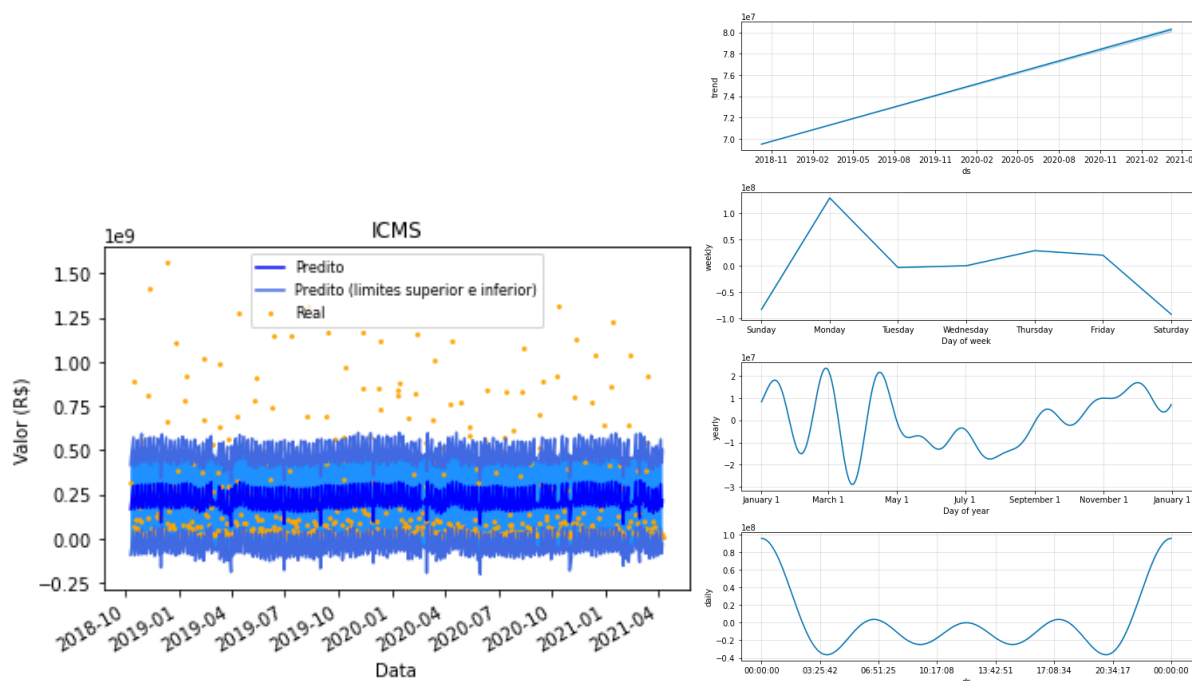


Figura 25 – Predição da arrecadação do ICMS (à esquerda) e componentes da predição (de cima para baixo: tendência, sazonalidade semanal, anual e diária), sem remoção de outliers




Figura 26 – Predição da arrecadação do IPVA (à esquerda) e componentes da predição (de cima para baixo: tendência, sazonalidade semanal, anual e diária), sem remoção de outliers

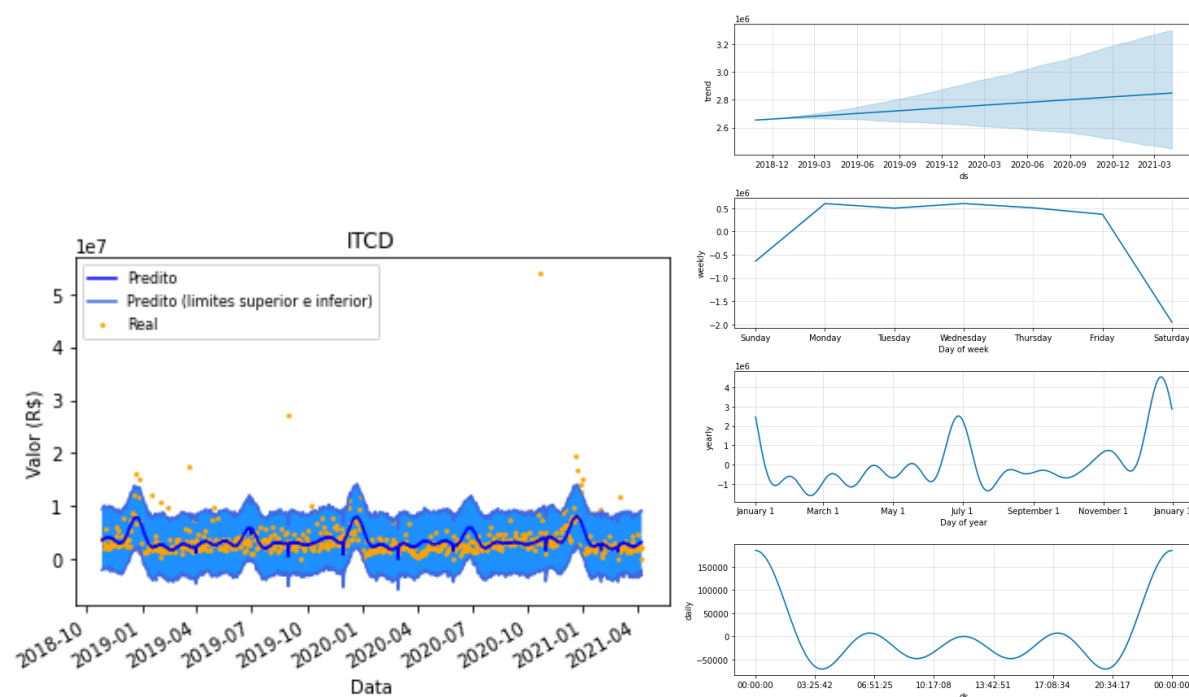


Figura 27 – Predição da arrecadação do ITCD (à esquerda) e componentes da predição (de cima para baixo: tendência, sazonalidade semanal, anual e diária), sem remoção de outliers

Tributo	RMSE (A)	Desvio Padrão set de testes (B)	A/B = (C)
ICMS	274.267.673,11	277.909.138,33	0,986897
IPVA	26.008.612,76	33.042.123,48	0,787135
ITCD	3.175.062,75	3.311.754,46	0,958725

Figura 28 – Root Mean Squared Error dos resíduos das predições do Prophet, sem exclusão de outliers

Ao realizar o treinamento sem excluir os *outliers*, verifica-se uma melhora na performance de todos os modelos, principalmente no IPVA, que teve uma redução de quase 22%. Conclui-se, portanto que a remoção dos outliers para as séries temporais destes três tributos é prejudicial às predições. Percebe-se que quanto mais sazonal é a série temporal, maior é o impacto da exclusão dos *outliers* nos erros das predições, muito provavelmente porque os *outliers* também possuem sazonalidade e sua remoção faz com que os modelos a ignorem. Comparando a figura 19 com a 22 e a 20 com a 23 é possível verificar claramente o potencial que os valores removidos dão aos modelos dos tributos com maior sazonalidade, que deixar de prever a arrecadação futura como uma linha quase horizontal (figuras 19 e 20) e passam a apresentar curvas mais condizentes com os valores reais (figuras 22 e 23). É possível visualizar também que nos modelos sem a exclusão de valores um maior número de pontos representativos dos valores reais se encontra dentro da área azul claro (margem de erro), comprovando mais uma vez a melhora da performance do modelo.

Com relação à tendência todos os modelos mantiveram previsões semelhantes às dos modelos com remoção de *outliers*. Com relação à sazonalidade, o ICMS permaneceu sem uma sazonalidade visível. Já o IPVA teve sua sazonalidade nos primeiros meses do ano, principalmente em janeiro, majorada por conta dos pagamentos à vista e das primeiras parcelas do tributo. Com relação ao ITCD ficou clara a sazonalidade do tributo nos meses de junho e janeiro, diferentemente do que apontava o modelo com remoção de outliers.

5.2.2. Rede Neural LSTM

5.2.2.1. Padronização dos dados

Diferentemente do Prophet, os dados inseridos nos modelos LSTM necessitam, além do adequado tratamento de *outliers*, de padronização, o que além de reduzir eventuais anomalias nos *datasets*, permite que os pesos sejam ajustados mais rapidamente durante o *backpropagation*⁷.

“Os dados para seu problema de predição de sequências provavelmente precisam ser escalados quando do treinamento de uma rede neural, tal como a

⁷ Algoritmo que ajusta os pesos atribuídos aos neurônios com o objetivo de reduzir o erro final do modelo. (Brownlee, Jason. *Long Short-Term Memory Networks With Python*. Machine Learning Mistery, 2017, p. 19)

rede neural recorrente LSTM. Quando uma rede neural é preenchida com dados não escalados que possuem um grande intervalo de valores (Ex.: quantidades em dezenas ou centenas) é possível que entradas com grandes valores reduzam a velocidade de aprendizado e a convergência da sua rede neural e, em alguns casos, não permite que a rede efetivamente aprenda o modelo”. (Brownlee, Jason. *Long Short-Term Memory Networks With Python*. Machine Learning Mastery, 2017, p. 27, livre tradução)⁸

Neste trabalho, como explicitado no item 4.3, serão utilizados três *scalers* do pacote *sklearn.preprocessing*: *StandardScaler*, *RobustScaler* e *PowerTransformer* (método *yeo-johnson*) e comparados os resultados no set de testes (out-of-sample), mediante treinamento com apenas 100 *epochs*, sendo utilizado no treinamento do modelo final aquele que obtiver menor erro. O *PowerTransformer* foi utilizado com o método *yeo-johnson* uma vez que o outro método, *box-cox*, só funciona com valores positivos e como foi visto no item 4.2, há valores negativos na base de dados, inviabilizando seu uso. O *StandardScaler* é um padronizador conhecido na estatística em que é subtraído de cada valor a média e o valor resultante dividido pelo desvio padrão:

$$valor_padronizado = \frac{x - \bar{x}}{\sigma}$$

Já o *RobustScaler* procura tratar melhor os *outliers*, subtraindo de cada valor a mediana e dividindo o valor resultante pelo intervalo interquartil (diferença entre o terceiro e primeiro quartis).

$$valor_padronizado = \frac{x - mediana}{Q_3 - Q_1}$$

Por sua vez, a transformação *yeo-johnson* do *PowerTransformer* é bem mais complexa, aplicando uma série de funções condicionais para resultar no valor transformado. O valor λ é determinado através da máxima verossimilhança estatística (maximum-likelihood estimation – MLE).

⁸ No original: The data for your sequence prediction problem probably needs to be scaled when training a neural network, such as a Long Short-Term Memory recurrent neural network. When a network is fit on unscaled data that has a range of values (e.g. quantities in the 10s to 100s) it is possible for large inputs to slow down the learning and convergence of your network, and in some cases prevent the network from effectively learning your problem.

$$valor_padronizado = \begin{cases} \{(x+1)^\lambda - 1\}/\lambda & (x \geq 0, \lambda \neq 0), \\ \log(x+1) & (x \geq 0, \lambda = 0), \\ -\{(-x+1)^{2-\lambda} - 1\}/(2-\lambda) & (x < 0, \lambda \neq 2), \\ -\log(-x+1) & (x < 0, \lambda = 2). \end{cases}$$

Quanto à estrutura da rede neural, apesar de já ter sido utilizada neste comparativo, deixarei para comentá-la no próximo item, dado que merece maior destaque e detalhamento.

```
# Cria modelo com única variável quantitativa utilizando LSTM
from src.ModelosUtil import LSTMUtil
from src.ModelosNN import LSTMUnivariada
import tensorflow.keras.optimizers as ko
from tensorflow import keras
from tensorflow.keras.callbacks import ModelCheckpoint, EarlyStopping, TensorBoard

comparativo = pd.DataFrame(columns=['StandardScaler', 'RobustScaler', 'PowerTransformer'])

for tributo in pd_arrecad_diaria['Tributo'].unique():
    # Utiliza o mesmo método do Prophet para tornar os resultados comparáveis
    df_treino, df_teste = ProphetUtil.divide_treino_teste(arrecad_diaria[tributo])
    print('Tributo ' + tributo + ' - Início DF teste : ' + str(
        df_teste.reset_index().loc[0, 'Data']) + ' Fim DF teste : ' + str(
        df_teste.reset_index().loc[len(df_teste) - 1, 'Data']))
    df_treino = LSTMUtil.transforma_dataframe(df_treino, 'Data')
    df_teste = LSTMUtil.transforma_dataframe(df_teste, 'Data')

    # Faz o Label Encoder do dia, dia da semana e mês (apesar de dia e mês serem numéricos, o Label Encoder inicia a contagem em 0 ao invés de 1)
    encoder_dia = LabelEncoder()
    dia_treino_enc = encoder_dia.fit_transform(df_treino['Dia'].values)
    dia_teste_enc = encoder_dia.transform(df_teste['Dia'].values)
    encoder_mes = LabelEncoder()
    mes_treino_enc = encoder_mes.fit_transform(df_treino['Mes'].values)
    mes_teste_enc = encoder_mes.transform(df_teste['Mes'].values)
    encoder_dia_semana = LabelEncoder()
    dia_semana_treino_enc = encoder_dia_semana.fit_transform(df_treino['Dia_Semana'].values)
    dia_semana_teste_enc = encoder_dia_semana.transform(df_teste['Dia_Semana'].values)
    encoder_dia_semana = LabelEncoder()
    dia_semana_treino_enc = encoder_dia_semana.fit_transform(df_treino['Dia_Semana'].values)
    dia_semana_teste_enc = encoder_dia_semana.transform(df_teste['Dia_Semana'].values)

    np_dia_mes_treino = np.concatenate((dia_treino_enc.reshape(-1, 1),
    mes_treino_enc.reshape(-1, 1), dia_semana_treino_enc.reshape(-1, 1)),
    axis=1)[5:]
    np_dia_mes_teste = np.concatenate((dia_teste_enc.reshape(-1, 1),
    mes_teste_enc.reshape(-1, 1), dia_semana_teste_enc.reshape(-1, 1)),
```

```

axis=1)[5:]

# Faz os testes com diversos "scalers" para verificar o com menor erro

# Standard Scaler
std_scaler = StandardScaler()
valor_treino_std = std_scaler.fit_transform(df_treino['Valor'].values.reshape(-1, 1))
valor_teste_std = std_scaler.transform(df_teste['Valor'].values.reshape(-1, 1))

# A saída (label) é a arrecadação do dia seguinte ao último dia da sequência
saida_treino = valor_treino_std[5:]
saida_teste = valor_teste_std[5:]

valor_arrecadacao_serie_temporal_lstm_treino = LSTMUtil.cria_intervalos_temporais(valor_treino_std)
valor_arrecadacao_serie_temporal_lstm_teste = LSTMUtil.cria_intervalos_temporais(valor_teste_std)

model = LSTMUnivariada(df_treino)
checkpoint = ModelCheckpoint('checkpoint_regressor_'+tributo+'_teste_standard_scaler.hdf5', monitor='loss', verbose=2,
                             save_best_only=True,
                             save_weights_only=False,
                             mode='auto', period=1)
model.compile(optimizer=ko.Adam(lr=0.1), loss='mse')
model.fit([np_dia_mes_treino, valor_arrecadacao_serie_temporal_lstm_treino], saida_treino, validation_data=([np_dia_mes_teste, valor_arrecadacao_serie_temporal_lstm_teste], saida_teste),
          epochs=100, batch_size=50, callbacks=[checkpoint])

# Carrega o melhor modelo salvo pelo Checkpoint
model.load_weights('checkpoint_regressor_'+tributo+'_teste_standard_scaler.hdf5')

std_pred = model.predict([np_dia_mes_teste, valor_arrecadacao_serie_temporal_lstm_teste])
mae_std = mean_absolute_error(std_scaler.inverse_transform(saida_teste), std_scaler.inverse_transform(std_pred))
print('O MAE para o tributo '+tributo+' usando o "Standard Scaler" foi de '+str(mae_std))

comparativo.loc[tributo, 'StandardScaler'] = mae_std

# Robust Scaler
rbt_scaler = RobustScaler()
valor_treino_rbt = rbt_scaler.fit_transform(df_treino['Valor'].values.reshape(-1, 1))
valor_teste_rbt = rbt_scaler.transform(df_teste['Valor'].values.reshape(-1, 1))

# A saída (label) é a arrecadação do dia seguinte ao último dia da sequência
saida_treino = valor_treino_rbt[5:]
saida_teste = valor_teste_rbt[5:]

valor_arrecadacao_serie_temporal_lstm_treino = LSTMUtil.cria_intervalos_temporais(valor_treino_rbt)
valor_arrecadacao_serie_temporal_lstm_teste = LSTMUtil.cria_intervalos_temporais(valor_teste_rbt)

model = LSTMUnivariada(df_treino)

```

```

checkpoint = ModelCheckpoint('checkpoint_regressor_'+tributo+'_teste_robust_scaler.hdf5', monitor='loss', verbose=2,
                             save_best_only=True,
                             save_weights_only=False,
                             mode='auto', period=1)
model.compile(optimizer=ko.Adam(lr=0.1), loss='mse')
model.fit([np_dia_mes_treino, valor_arrecadacao_serie_temporal_lstm_treino], saida_treino, validation_data=([np_dia_mes_teste, valor_arrecadacao_serie_temporal_lstm_teste], saida_teste),
          epochs=100, batch_size=50, callbacks=[checkpoint])

# Carrega o melhor modelo salvo pelo Checkpoint
model.load_weights('checkpoint_regressor_'+tributo+'_teste_robust_scaler.hdf5')

rbt_pred = model.predict([np_dia_mes_teste, valor_arrecadacao_serie_temporal_lstm_teste])
mae_rbt = mean_absolute_error(rbt_scaler.inverse_transform(saida_teste), rbt_scaler.inverse_transform(rbt_pred))
print('O MAE para o tributo '+tributo+' usando o "Robust Scaler" foi de '+str(mae_rbt))

comparativo.loc[tributo, 'RobustScaler'] = mae_rbt

# Power Transformer (yeo-johnson)
pwr_scaler = PowerTransformer()
valor_treino_pwr = pwr_scaler.fit_transform(df_treino['Valor'].values.reshape(-1, 1))
valor_teste_pwr = pwr_scaler.transform(df_teste['Valor'].values.reshape(-1, 1))

# A saída (label) é a arrecadação do dia seguinte ao último dia da sequência
saida_treino = valor_treino_pwr[5:]
saida_teste = valor_teste_pwr[5:]

valor_arrecadacao_serie_temporal_lstm_treino = LSTMUtil.cria_intervalos_temporais(valor_treino_pwr)
valor_arrecadacao_serie_temporal_lstm_teste = LSTMUtil.cria_intervalos_temporais(valor_teste_pwr)

model = LSTMUnivariada(df_treino)
checkpoint = ModelCheckpoint('checkpoint_regressor_'+tributo+'_teste_power_transformer.hdf5', monitor='loss', verbose=2,
                             save_best_only=True,
                             save_weights_only=False,
                             mode='auto', period=1)
model.compile(optimizer=ko.Adam(lr=0.1), loss='mse')
model.fit([np_dia_mes_treino, valor_arrecadacao_serie_temporal_lstm_treino], saida_treino, validation_data=([np_dia_mes_teste, valor_arrecadacao_serie_temporal_lstm_teste], saida_teste),
          epochs=100, batch_size=50, callbacks=[checkpoint])

# Carrega o melhor modelo salvo pelo Checkpoint
model.load_weights('checkpoint_regressor_'+tributo+'_teste_power_transformer.hdf5')

pwr_pred = model.predict([np_dia_mes_teste, valor_arrecadacao_serie_temporal_lstm_teste])
mae_pwr = mean_absolute_error(pwr_scaler.inverse_transform(saida_teste), pwr_scaler.inverse_transform(pwr_pred))
print('O MAE para o tributo '+tributo+' usando o "Power Transformer" foi de '+str(mae_pwr))

```

```
comparativo.loc[tributo, 'PowerTransformer'] = mae_pwr
```

Figura 29 – Trecho do código em que são comparados os diversos scalers para normalização dos dados para a rede neural LSTM

Tributo	StandardScaler	RobustScaler	PowerTransformer
ICMS	115.762.908,93	199.449.107,75	115.261.123,26
IPVA	10.102.122,66	8.472.645,06	7.935.259,68
ITCD	2.085.123,60	2.085.306,60	1.760.417,32

Figura 30 – Comparativo do Mean Absolut Error (Erro Médio Absoluto) – MAE entre os scalers para cada tributo

6. Links

7. Referências